

=====

INFORME TÉCNICO Algoritmo FOIL: Inducción de Reglas y Cálculo de Ganancia

=====

Ejercicio 1: Identificar empleados en formación

Este ejercicio permite practicar cómo inducir reglas lógicas simples a partir de diferencias entre ejemplos positivos y negativos, tal como lo hace el algoritmo FOIL en su forma más básica.

Se tiene un conjunto de datos con personas que trabajan en una empresa. Algunas están en formación (aprendices) y otras no. Cada persona tiene atributos como:

- edad
- departamento
- nivel_educativo
- en_formacion (booleano: `True` o `False`)

Dataset de ejemplo:

```
datos = [  
    {"edad": 22, "departamento": "IT", "nivel_educativo": "terciario", "en_formacion": True},  
    {"edad": 24, "departamento": "IT", "nivel_educativo": "universitario", "en_formacion":  
True},  
    {"edad": 21, "departamento": "RRHH", "nivel_educativo": "terciario", "en_formacion":  
True},  
    {"edad": 35, "departamento": "IT", "nivel_educativo": "universitario", "en_formacion":  
False},  
    {"edad": 40, "departamento": "Finanzas", "nivel_educativo": "maestría", "en_formacion":  
False},  
    {"edad": 29, "departamento": "RRHH", "nivel_educativo": "universitario",  
"en_formacion": False},  
    {"edad": 23, "departamento": "IT", "nivel_educativo": "terciario", "en_formacion": True},  
    {"edad": 38, "departamento": "Finanzas", "nivel_educativo": "universitario",  
"en_formacion": False}  
]
```

Objetivo del ejercicio:

1. Separar los ejemplos positivos (`en_formacion == True`) y negativos (`en_formacion == False`).

2. Para cada atributo, identificar los valores que aparecen en los positivos pero no en los negativos.
3. Desarrollar un programa en Python que muestre la Regla inducida para identificar a personas en formación:

Regla inducida para identificar a personas en formación:

Respuestas a las preguntas guía:

- ¿Qué valores de departamento aparecen solo en los positivos?

Respuesta: Ninguno, dado que los que aparecen en 'positivos' son IT y RRHH, pero también aparecen en 'negativos'.

- ¿Qué niveles educativos son comunes en los positivos pero no en los negativos?

Respuesta: Terciario, aparece 3 veces en positivos y 0 en negativos.

- ¿Qué edades aparecen solo en los positivos?

Respuesta: 21, 22, 23 y 24, en este dataset todas las personas con 24 años o menos pertenecen al grupo de los positivos.

Ejercicio 2:

A) Programa en Python (Condición: nivel_educativo == 'terciario')

Desarrollar un programa en Python que obtenga el cálculo del FOIL Gain para la condición nivel_educativo == 'terciario', con la siguiente salida:

Condición: nivel_educativo == 'terciario'

P (positivos antes) = 4

N (negativos antes) = 4

p (positivos después) = 3

n (negativos después) = 0

$p / (p + n) = 1.000$

$P / (P + N) = 0.500$

$\log_2(p / (p + n)) = 0.000$

$\log_2(P / (P + N)) = -1.000$

FOIL Gain = 3.000

B) Cálculo de FOIL Gain manual

Realizar el cálculo de FOIL Gain manual para comprobar los cálculos.

Condición: nivel_educativo == 'terciario'

Valores utilizados:

Término	Valor
P (positivos antes)	4
N (negativos antes)	4
p (positivos después)	3
n (negativos después)	0

1. Fracción después de aplicar la condición: *1*
2. Fracción antes de aplicar la condición: *0,5*
3. Logaritmos: *Después de log2(1): 0 / Antes de log2(0,5): -1*
4. FOIL Gain: *3*
5. Interpretación:

#Fórmula

$$\text{FOIL Gain} = p * (\log_2(p / (p + n)) - \log_2(P / (P + N)))$$

1.Fracción después de aplicar la condición

$$p / (p + n)$$

$$3 / (3 + 0)$$

$$3 / 3$$

$$= 1$$

2.Fracción antes de aplicar la condición

$$P / (P + N)$$

$$4 / (4 + 4)$$

$$4 / 8$$

$$= 0,5$$

3. Logaritmos

- Después de aplicar condición:

$$\log_2(3 / (3 + 0))$$

$$\log_2(1)$$

$$= 0$$

- Antes de aplicar la condición:

$$\log_2(4 / (4 + 4))$$

$$\log_2(0,5)$$

$$= -1$$

4.Cálculo del FOIL Gain

$$p * (\log_2(p / (p + n)) - \log_2(P / (P + N)))$$

$$3 * (\log_2(3 / (3 + 0)) - \log_2(4 / (4 + 4)))$$

$$3 * (\log_2(1) - \log_2(0,5))$$

$$3 * (0 - (-1))$$

$$3 * 1$$

$$= 3$$

5. Interpretación

La condición `nivel_educativo == 'terciario'` mejora la pureza de la regla. Antes de aplicarla la mitad de los ejemplos eran positivos. Luego de aplicarla todos los ejemplos que cumplen dicha condición son positivos, dado que no cubren ningún negativo.

Además cubre de tres de los cuatro positivos, por eso el FOIL Gain es alto (3). Esto demuestra que es un buen literal para comenzar la regla.

C) Programa en Python (Condición: edad <= 23)

Desarrollar un programa en Python que obtenga el cálculo del FOIL Gain para la condición edad <= 23, con la siguiente salida:

P (positivos antes) = 4
N (negativos antes) = 4
p (positivos después) = 3
n (negativos después) = 0
 $p / (p + n) = 1.000$
 $P / (P + N) = 0.500$
 $\log_2(p / (p + n)) = 0.000$
 $\log_2(P / (P + N)) = -1.000$
FOIL Gain = 3.000

D) Cálculo de FOIL Gain manual

Realizar el cálculo de FOIL Gain manual para comprobar los cálculos.

Condición: edad <= 23

Valores utilizados:

Término	Valor
P (positivos antes)	4
N (negativos antes)	4
p (positivos después)	3
n (negativos después)	0

1. Fracción después de aplicar la condición: 1
2. Fracción antes de aplicar la condición: 0,5
3. Logaritmos: Después de $\log_2(1)$: 0 / Antes de $\log_2(0,5)$: -1
4. FOIL Gain: 3
5. Interpretación:

1.Fracción después de aplicar la condición

$$p / (p + n)$$

$$3 / (3 + 0)$$

$$3 / 3$$

$$= 1$$

2.Fracción antes de aplicar la condición

$$P / (P + N)$$

$$4 / (4 + 4)$$

$$4 / 8$$

$$= 0,5$$

3.Logaritmos

-Después de aplicar condición:

$$\log_2(3 / (3 + 0))$$

$$\log_2(1)$$

$$= 0$$

-Antes de aplicar la condición:

$$\log_2(4 / (4 + 4))$$

$$\log_2(0,5)$$

$$= -1$$

4.Cálculo del FOIL Gain

$$3 * (\log_2(3 / (3 + 0)) - \log_2(4 / (4 + 4)))$$

$$3 * (\log_2(1) - \log_2(0,5))$$

$$3 * (0 - (-1))$$

$$3 * 1$$

$$= 3$$

5.Interpretación.

La condición edad ≤ 23 cubre tres de los cuatro positivos sin cubrir ningún negativo, obteniendo también en este caso un FOIL Gain alto (3). Pero cabe destacar que, aunque el resultado es numéricamente idéntico al calculo que se obtuvo con la condición nivel_educativo == 'terciario' (producto de que en este dataset las personas ≤ 23 tienen un nivel educativo 'terciario'), la diferencia reside en que en este caso se trata de un atributo numérico continuo en lugar de uno categórico, lo que cambia como la regla generalizaría nuevos datos ingresados.